การตรวจจับความผิดปกติบนพื้นผิวโลหะ

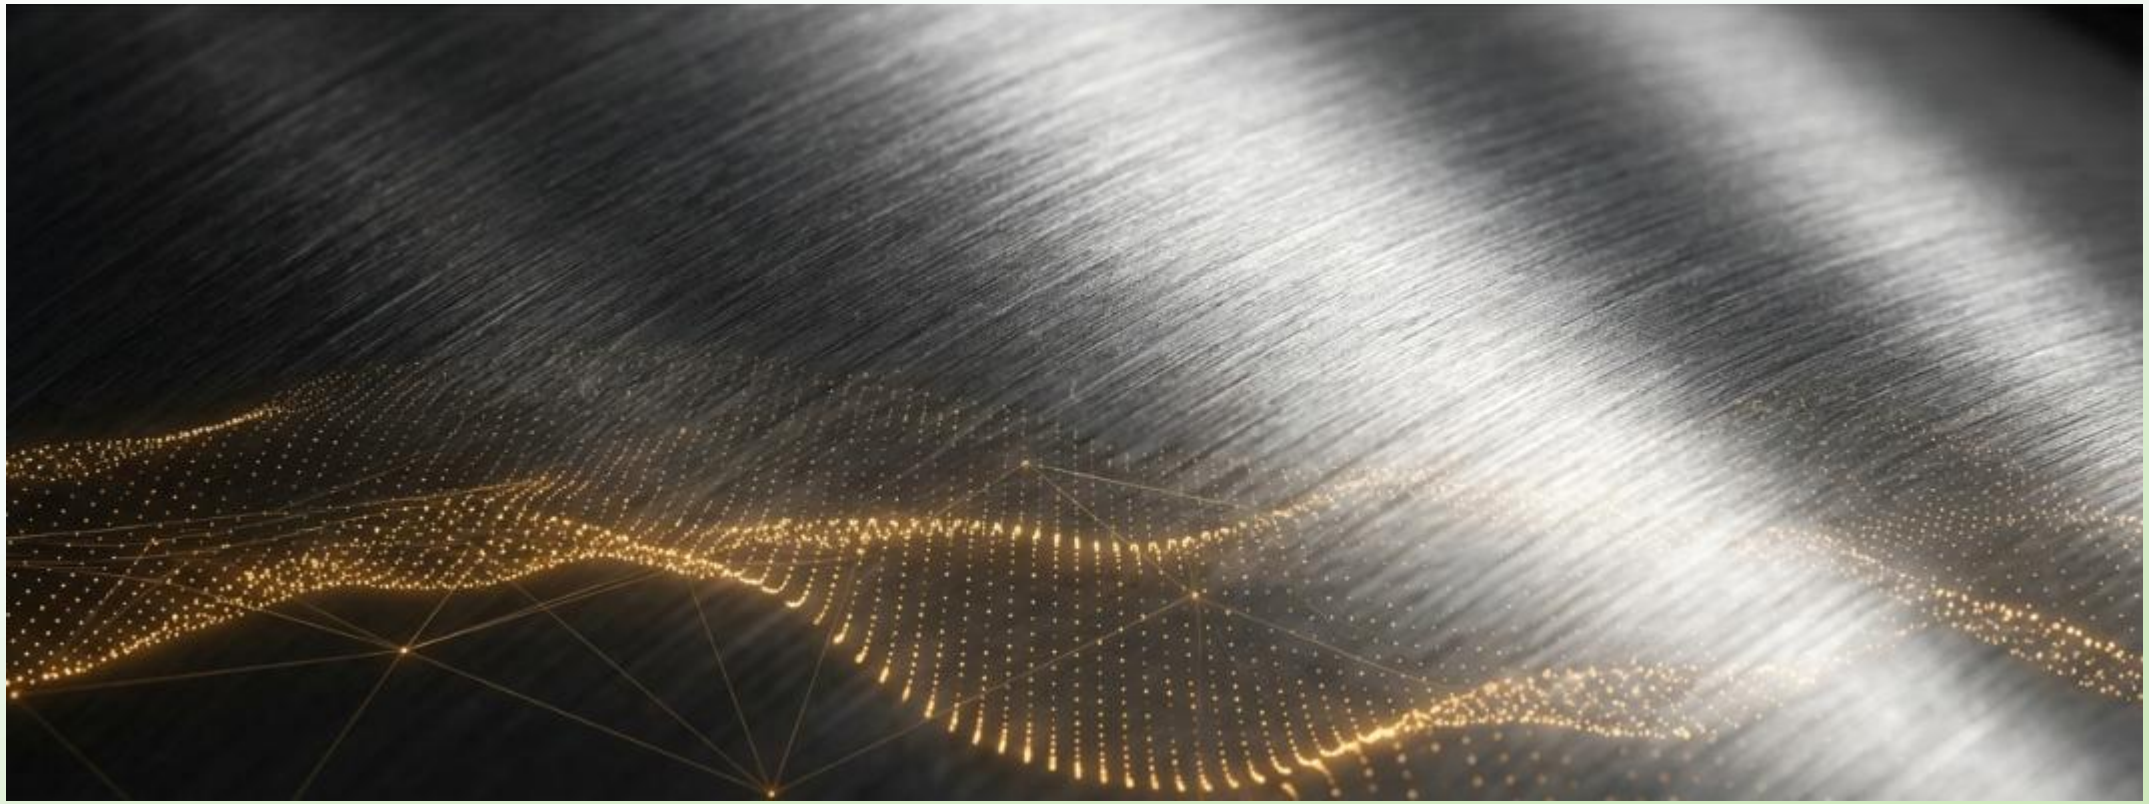

การใช้พลังงานในอุตสาหกรรมโลหะ

การใช้พลังงานทั่วโลกในปี 2018

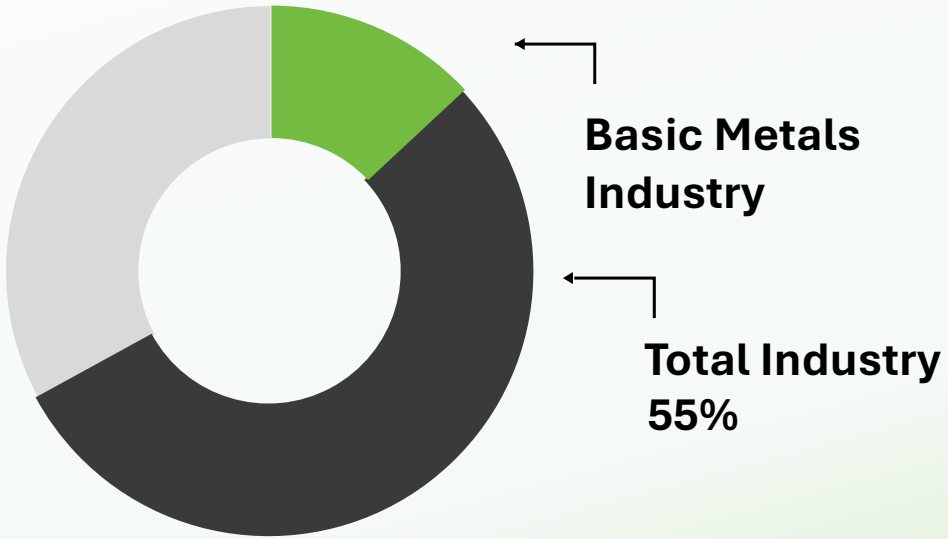

อุตสาหกรรมโลหะใช้พลังงานมหาศาลถึง

12%

ของการใช้พลังงานภาคอุตสาหกรรมทั่วโลกจากทั้งหมดร้อยละ

55

รากฐานสำคัญ ของอุตสาหกรรมยานยนต์และอิเล็กทรอนิกส์

‘Surface Integrity’

ความสมบูรณ์ของพื้นผิว (Surface Integrity) ไม่ได้เป็นเพียงประเด็นด้านความสวยงาม แต่เป็นตัวชี้วัดคุณภาพ ความน่าเชื่อถือ และมูลค่าทางเศรษฐกิจของผลิตภัณฑ์โดยตรง

Energy Information Administration (EIA) สำนักงานสารสนเทศด้านพลังงานของสหรัฐอเมริกา

ปัญหาของมนุษย์

ความไม่แน่นอนในการตรวจสอบผิวโลหะด้วยสายตามนุษย์ (Uncertainty in Manual Visual Inspection) อ้างอิงจากงานวิจัย: *Stallard et al. (2018), Journal of Manufacturing Systems*

แค่ **66.83%**

ความสามารถในการทำซ้ำ (Repeatability)

มี **18-35%**

บอกของดีว่ามีตำหนิ (False Alarm)

สูงถึง **30-40%**

ปล่อยของมีตำหนิหลุด (Miss)

Stallard et al. (2018), Journal of Manufacturing Systems

ผลกระทบทางธุรกิจ

ด้วยอัตราการหลุดรอดที่สูงถึง
30%

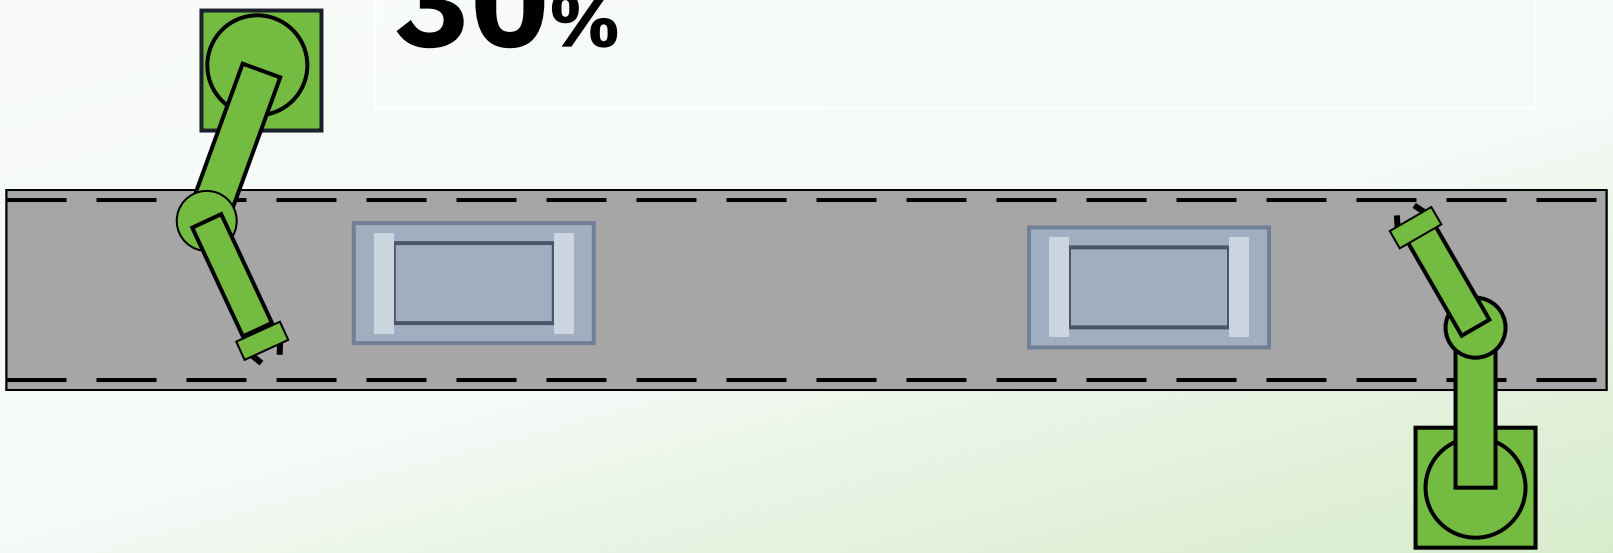

Zero-Defect Manufacturing
เป็นไปไม่ได้ในเชิงสถิติ

○ นี่ไม่ใช่ปัญหาของบุคลากร แต่เป็น ข้อจำกัดเชิงระบบ ของวิธีการตรวจสอบที่ไม่สามารถทำซ้ำได้อย่างสม่ำเสมอ

Stallard et al. (2018), Journal of Manufacturing Systems

ผลกระทบทางธุรกิจ

ความเสียหายที่มากกว่าต้นทุนการผลิต: Cost of Poor Quality (COPQ)

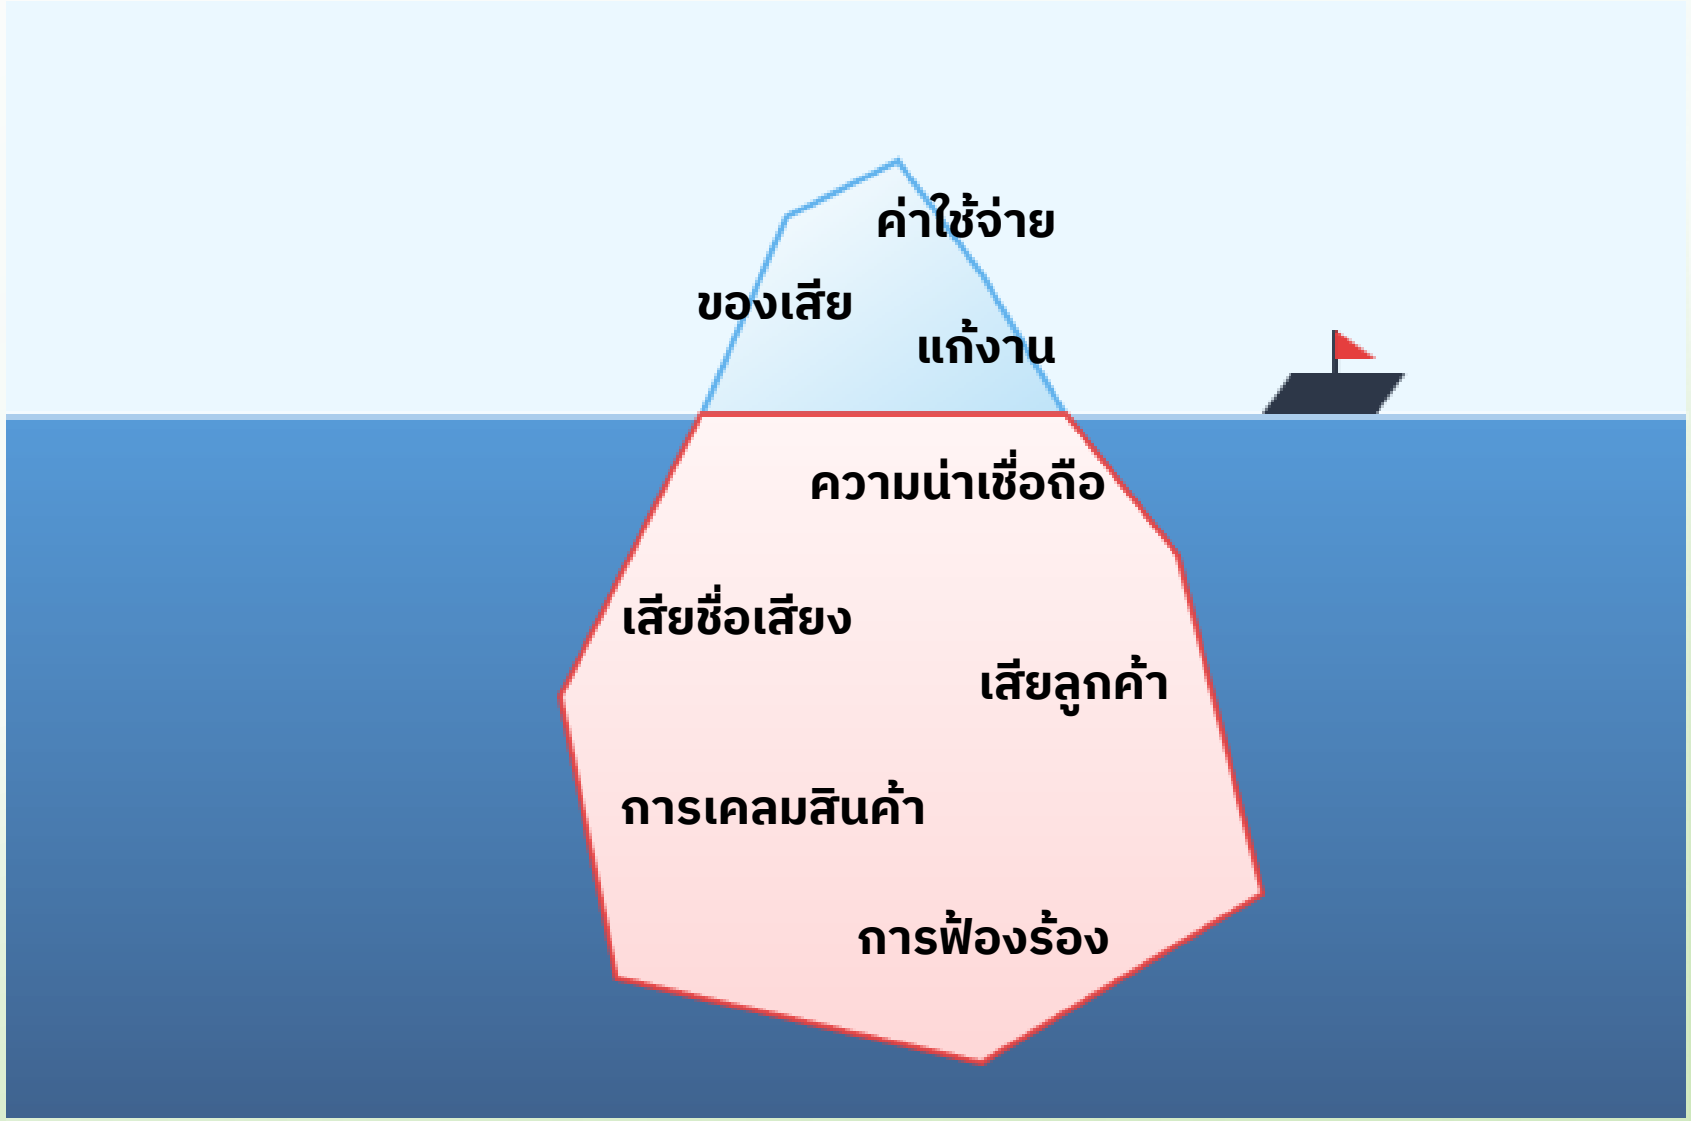

ภาพรวมวิธีการ

1.

Photometric Stereo
-หารูปทรงที่ของวัตถุ
-แก้ปัญหาเรื่องการสะท้อนของแสง

2.

Synthetic Defect Generation
-เพิ่มข้อมูลที่มีตำหนิ
-เพิ่มประสิทธิภาพในการทำนาย

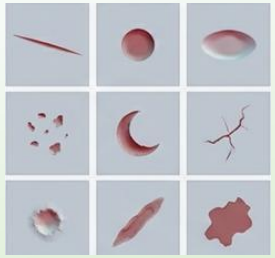

3.

Lightweight Deep Learning
-โมเดลขนาดเล็ก
-แก้ปัญหาเรื่องค่าใช้จ่ายและความเร็ว

Limitation 1 (Reflection)

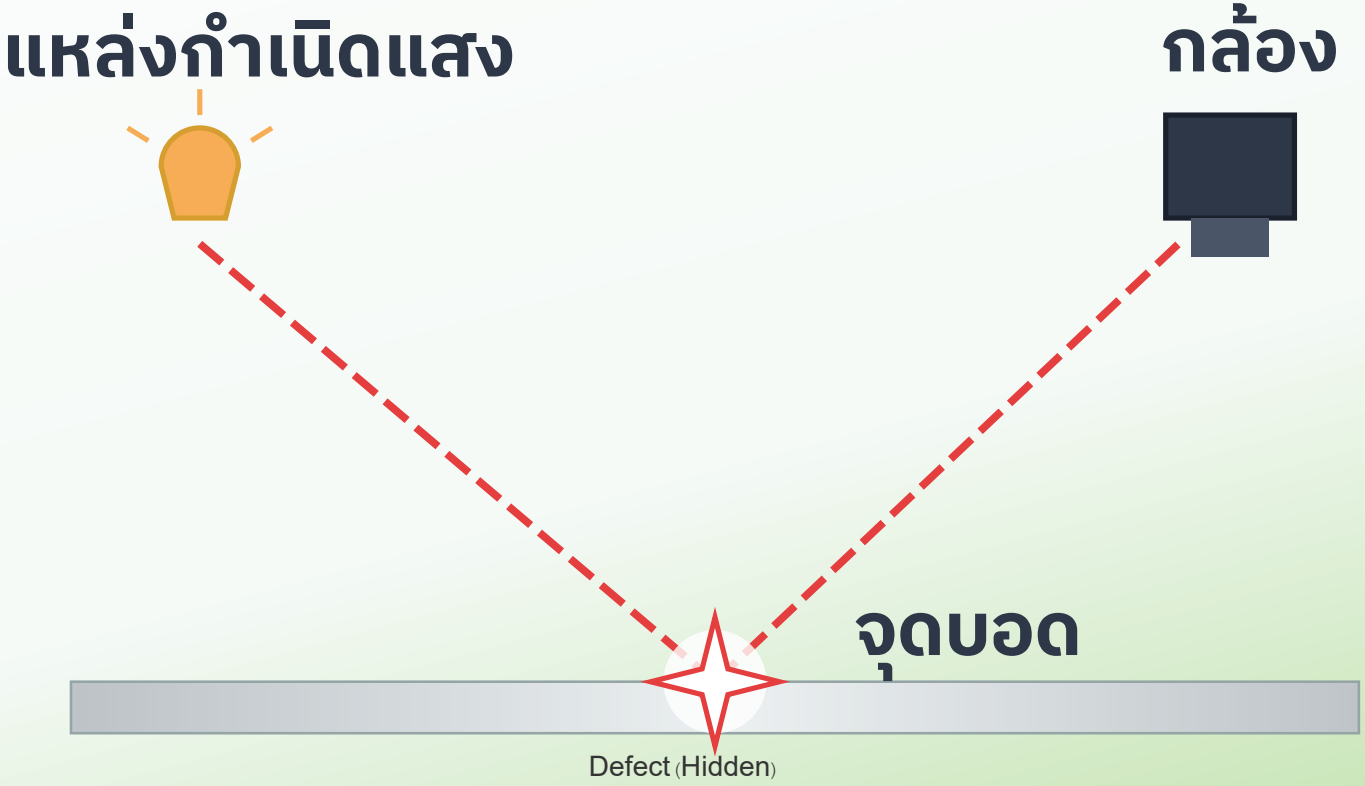

แสงที่จ้าทำให้บังตำหนิได้

ผลลัพธ์

Solution 1 (The Eye)

Acquisition: Photometric Stereo

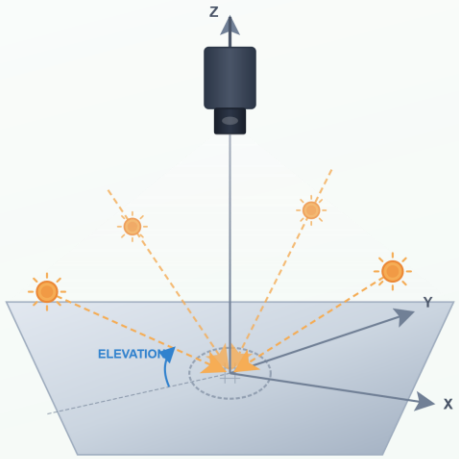

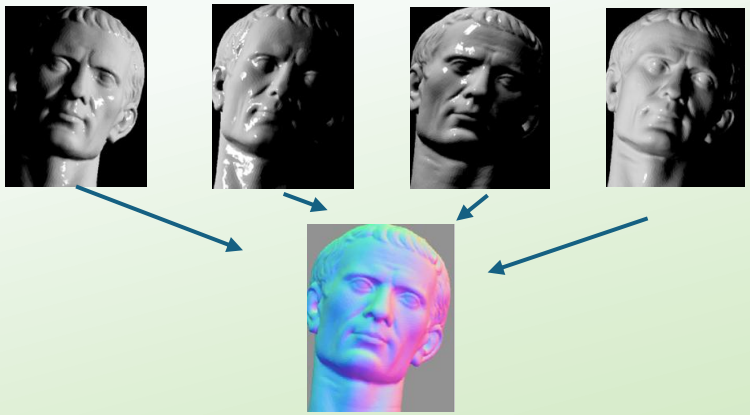

“มุมมองเดิม แต่เปลี่ยนไฟ”

- ถ่ายภาพหลายภาพจากมุมมองเดิม แต่เปลี่ยนทิศทางแสงไปเรื่อยๆ
- หากภาพหนึ่งเกิดแสงจ้า ยังมีภาพอื่นในทิศทางแสงที่แตกต่างกันมาทดแทนได้
- อัลกอริทึมจะนำข้อมูลจากทุกภาพมารวมกัน (Fusion) เพื่อตัดส่วนที่เป็นแสงสะท้อนรบกวนออก และกู้คืนข้อมูลพื้นผิวที่แท้จริงกลับมา

Robert J. Woodham (1980)

Solution 1 (The Eye)

Acquisition: Photometric Stereo

การแยกคุณสมบัติพื้นผิว

- Surface Normal: จะคำนวณหาอาศัยการเปลี่ยนแปลงของความเข้มแสงเมื่อทิศทางแสงเปลี่ยนไป
- Albedo: ความสว่างหรือสีที่แท้จริงของวัสดุโดยตัดผลกระทบจากแสงเงาและความโค้งนูนออกไป

ทั่วไป

เกิดปัญหา แสงจ้า ,เงา

Normal Map

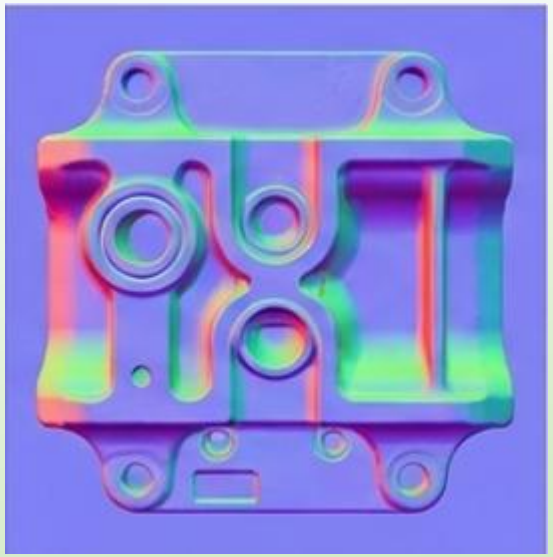

รอยขีดข่วน,รอยบุบ,รอยถลอก

Albedo Map

คราบสนิม,คราบน้ำมัน

Robert J. Woodham (1980)

Limitation 2 (Data Imbalance)

- ในกระบวนการผลิตจะสร้างของเสียหรือ defect ได้น้อยมาก
- ข้อมูลของเสียน้อยเกินไป โมเดลจะเรียนรู้แต่ของดี จนแยกแยะของเสียไม่ออก

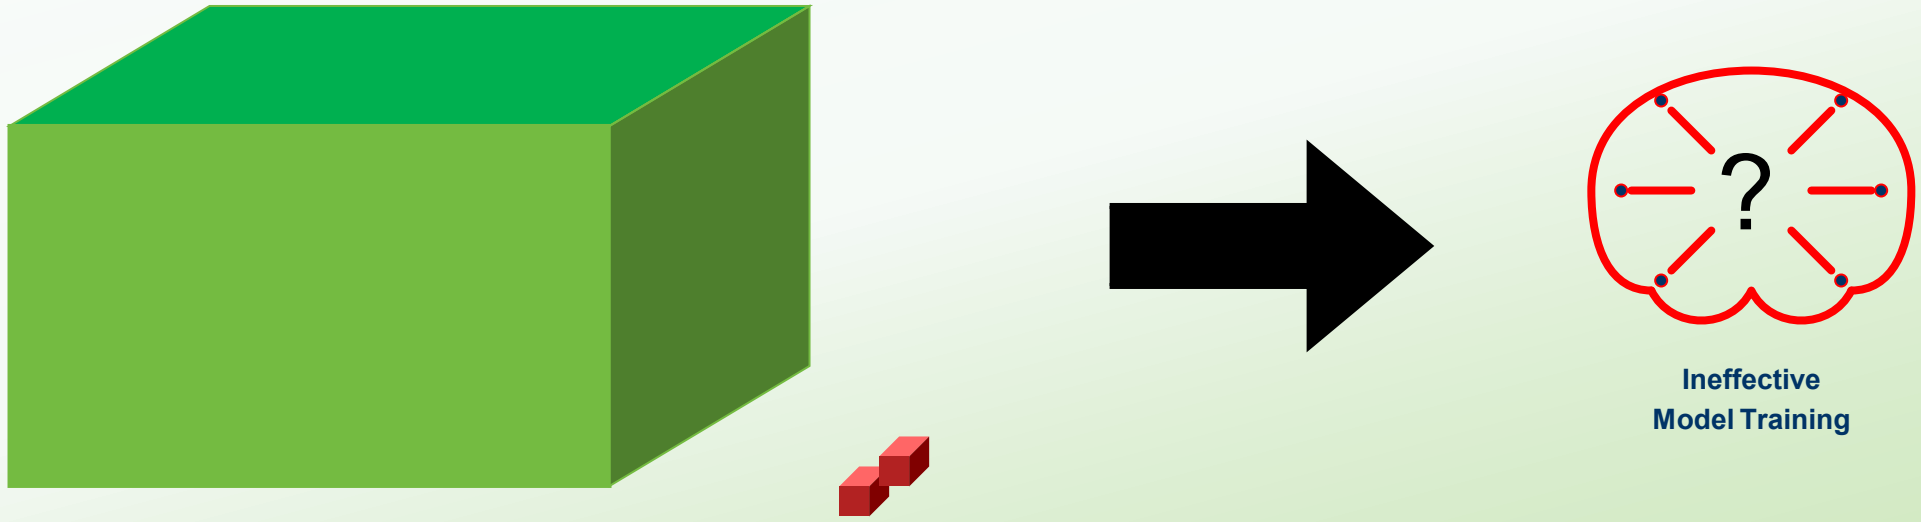

Good data (99.9%)

Defect data (0.1%)

Solution 2 (The Simulator)

Augmentation: Synthetic Defect Generation

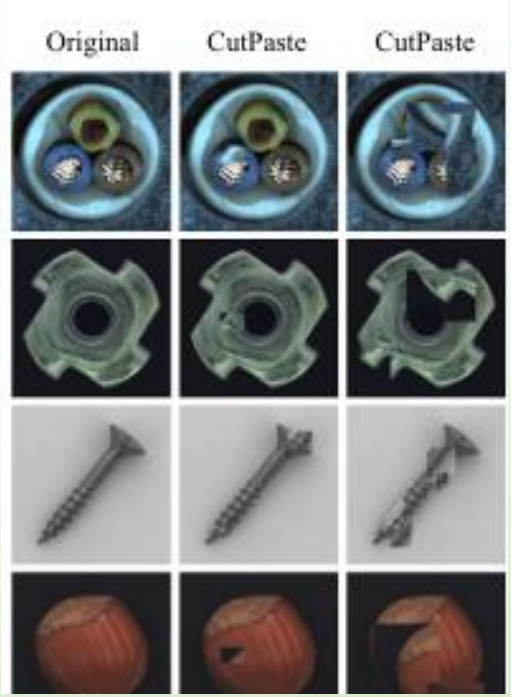

CutPaste: ตัด(Cut) และแปะ (Paste) ลงในตำแหน่งอื่นของภาพเพื่อสร้างความไม่ต่อเนื่อง (Irregularity)

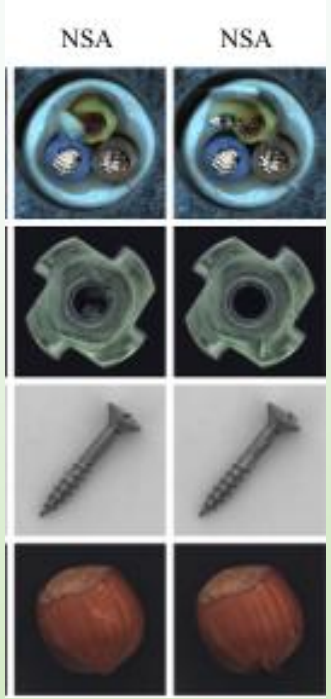

NSA (Natural Synthetic Anomalies): ใช้ Poisson image editing ในการผสานภาพตำหนิ

CutPaste: อ้างอิงจาก *Li et al. (2021), Google Cloud AI Research*

NSA: อ้างอิงจาก *Schlüter et al. (2023)*

Limitation 3 (Speed & Cost)

- ความคุ้มค่าในการลงทุนเป็นปัจจัยสำคัญ (ROI)
- ใช้โมเดลที่มีขนาดเล็ก ทำงานได้รวดเร็ว และให้ประสิทธิภาพ (Cost Efficiency)
- ไม่เพิ่มต้นทุนด้านฮาร์ดแวร์และพลังงานมากเกินความจำเป็น

Traditional Model

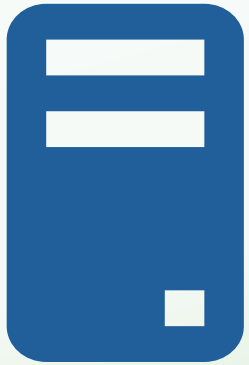

£££

Lightweight Model

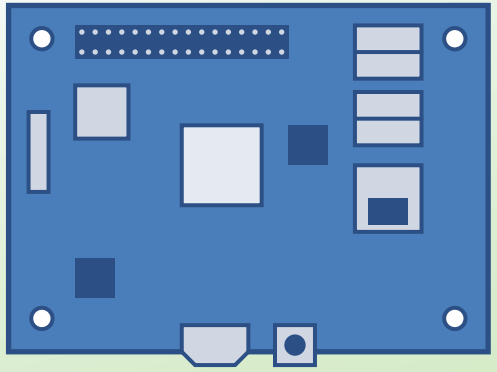

£ 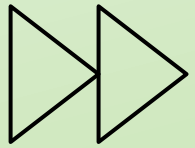

Solution 3 (The Speed)

Inference: EfficientAD & Lightweight Architecture

- เปเปอร์นี้ถูกออกแบบมาเพื่อแก้ปัญหา "Real-world Industrial Inspection" โดยเฉพาะ คือต้อง **แม่นยำ (Accurate)** และ **เร็วระดับมิลลิวินาที (Fast)**
- Concept: เราใช้เทคนิคที่เรียกว่า Student-Teacher Learning
  - Teacher **(อาจารย์):** เป็นโมเดลตัวใหญ่ ฉลาด รู้ลึกว่า "ผิวโลหะปกติที่ดี" หน้าตาเป็นยังไง (แต่ทำงานช้า)
  - Student **(ลูกศิษย์):** เป็นโมเดลตัวเล็ก ที่ถูกฝึกให้ "เลียนแบบ" อาจารย์ทุกอย่าง (ทำงานเร็วมาก)
- **การทำงาน:** เราส่งภาพเข้าไประบบ
  - ถ้าเป็น **"ผิวงานดี"**: ลูกศิษย์จะตอบเหมือนอาจารย์เป๊ะ (ผ่าน)
  - ถ้าเป็น **"ผิวงานเสีย" (Defect)**: ลูกศิษย์ไม่เคยเห็นมาก่อน จะเริ่มลนลานและตอบไม่เหมือนอาจารย์

อ้างอิงจากงานวิจัยเรื่อง "EfficientAD: Accurate Visual Anomaly Detection at Millisecond-Level Latencies" โดย Batzner et al. (2024)

Solution 3 (The Speed)

ผลลัพธ์การทำนาย

Anomaly Score

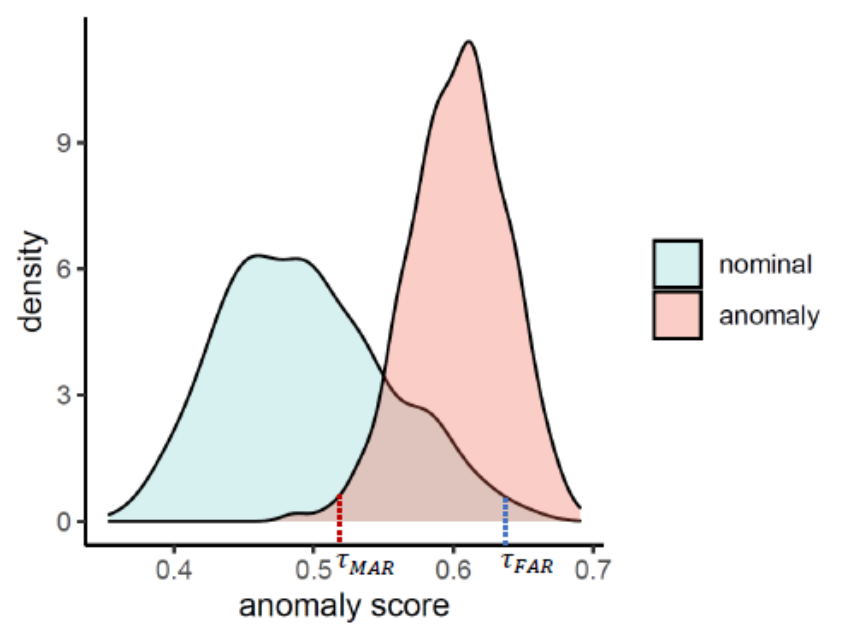

Anomaly Map (Heatmap)

Original

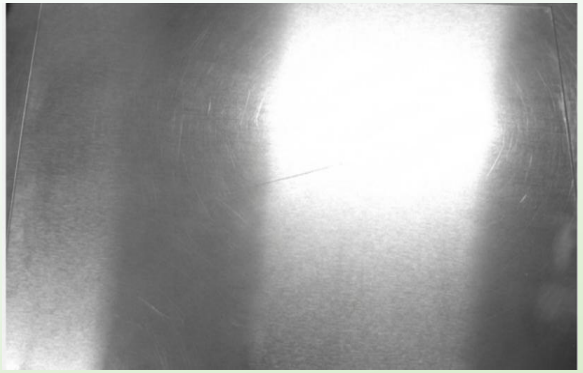

Anomal Map

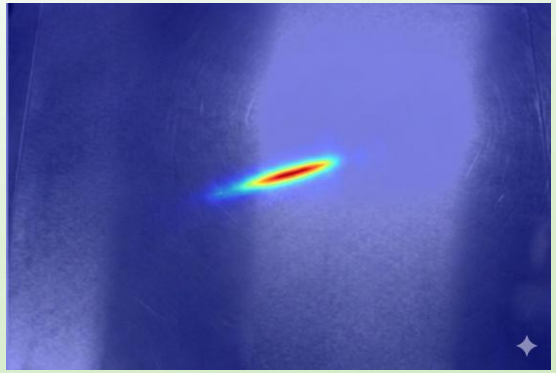

อ้างอิงจากงานวิจัยเรื่อง "EfficientAD: Accurate Visual Anomaly Detection at Millisecond-Level Latencies" โดย Batzner et al. (2024)

Solution 3 (The Speed)

การประเมินผลประสิทธิภาพ

AUROC

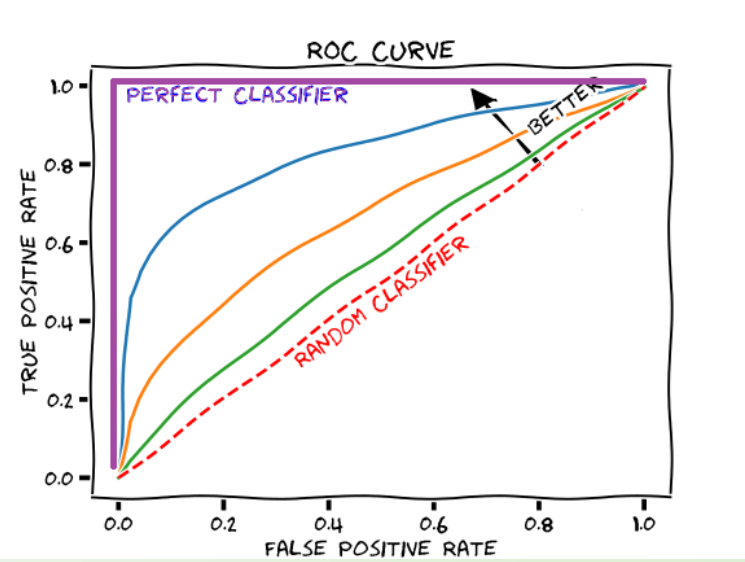

Inference Time

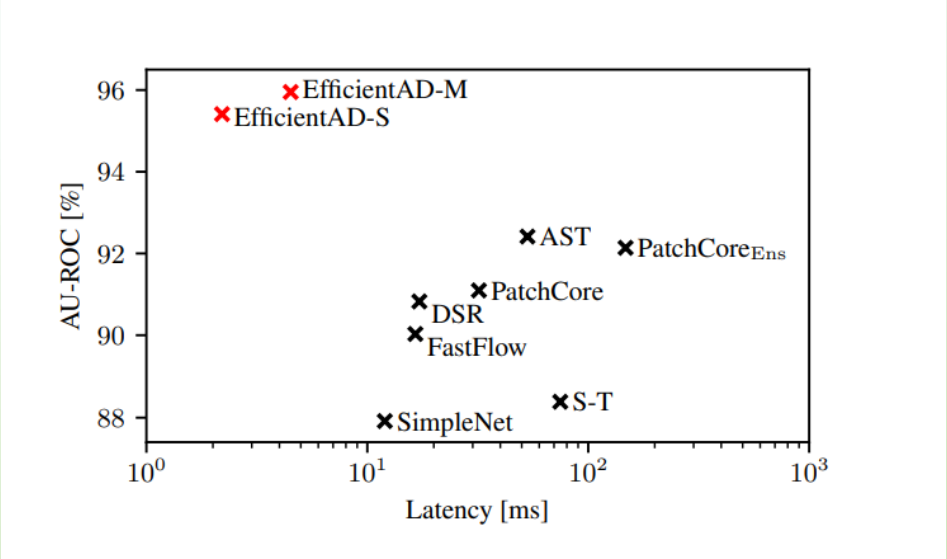

อ้างอิงจากงานวิจัยเรื่อง "EfficientAD: Accurate Visual Anomaly Detection at Millisecond-Level Latencies" โดย Batzner et al. (2024)

สรุปกระบวนการทำงานของระบบ

Fully Automated Workflow ที่สมบูรณ์ ผสานเทคโนโลยีการถ่ายภาพ (Imaging), การสร้างข้อมูล (Data Augmentation) และ AI ประสิทธิภาพสูง

เพื่อให้มั่นใจว่า “**การตรวจสอบคุณภาพจะไม่ใช่แค่การสุ่ม แต่คือ Total Quality Coverage** ที่รวดเร็ว แม่นยำ และคุ้มค่าการลงทุน”

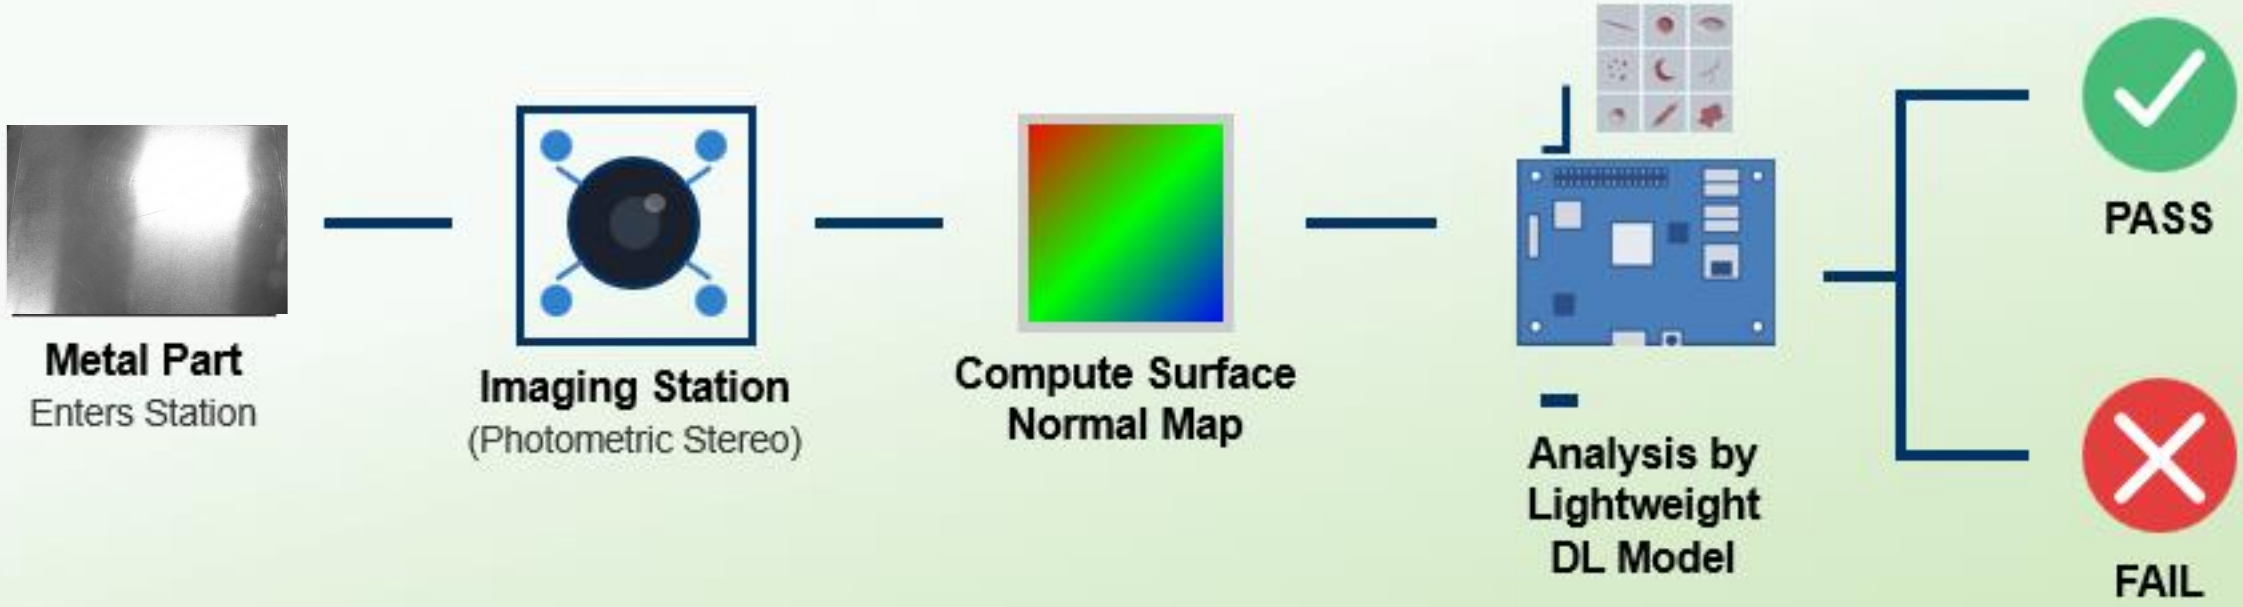

“Thank you”

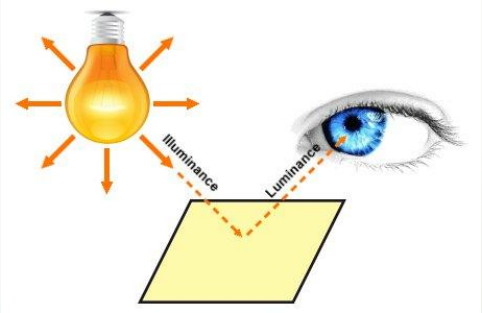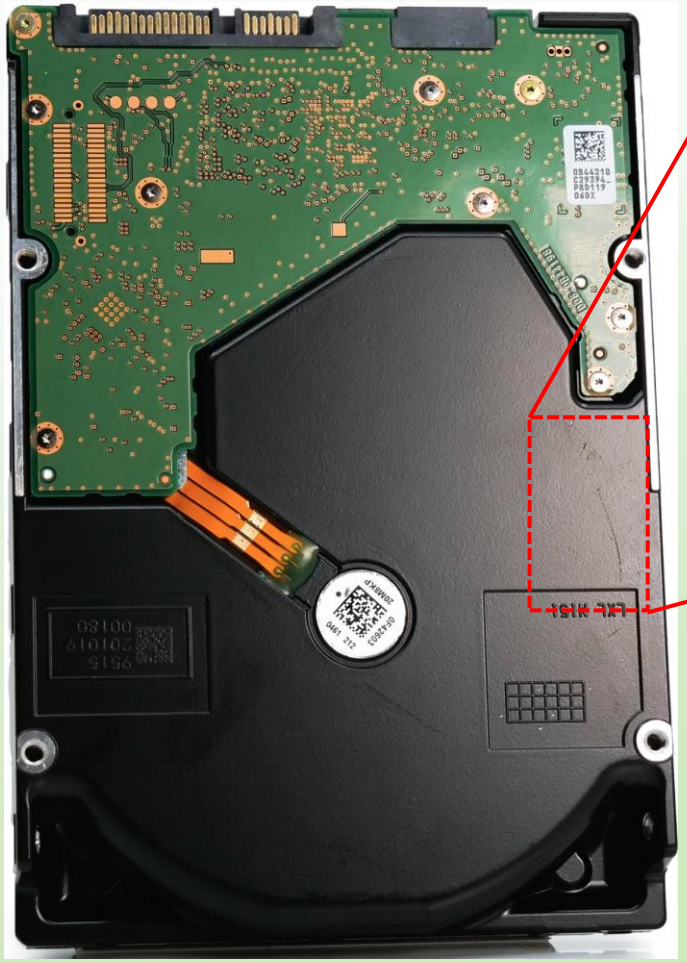
Illuminance
Luminance